

OBJETIVO DEL PROYECTO.....	2
DATASET PRINCIPAL.....	2
1.- Contexto del dataset.....	2
2.- Fuente.....	2
3.- ¿Qué campos tiene?.....	2
4.- Tratamiento del dataset.....	2
DATASET ADICIONAL.....	3
1.- Contexto del dataset.....	3
2.- Fuente.....	3
3.- ¿Qué campos tiene?.....	3
4.- Proceso para obtener la info.....	3
5.- Tratamiento del dataset.....	4
CÓMO QUEDA EL DATASET FINAL.....	4
1.- Agrupaciones para análisis de datos.....	4
1.1.- hora redondeada.....	4
1.2.- El resto de grupos.....	4
ANÁLISIS DE LOS DATOS.....	5
1.- Heatmap.....	6
2.- Pacientes por mes y año.....	6
3.- Ámbito por paciente.....	7
4.- Predominancia de edades por visitas.....	7
5.- Predominancia del género y el triaje.....	8
6.- Predominancia de edad y triaje.....	9
7.- Horas puntas en urgencias.....	9
8.- Temperatura media con más visitas a urgencias.....	10
9.- Precipitaciones por visitas a urgencias.....	11
CONCLUSIONES TRAS VISUALIZAR LAS GRÁFICAS.....	11
LLAMADA A LA API PARA OBTENER CLIMATOLOGÍA.....	12
TRANSFORMACIÓN DE DATOS.....	12
USANDO MODELOS PREDEFINIDOS.....	13
1.- PROPHET.....	13
1.1.- Transformaciones para prophet.....	14
2.- SARIMAX.....	14
1.1.- Transformaciones para Sarimax.....	15
3.- ARIMA Y ALISADO EXPONENCIAL.....	15
COMPARANDO MODELOS PREDEFINIDOS.....	15
EJEMPLO REAL.....	16
CÓMO EJECUTAR EL CÓDIGO.....	17
MEJORAS OPCIONALES PARA FUTURAS VERSIONES.....	17
PRIMERA MEJORA.....	17
SEGUNDA MEJORA.....	18

OBJETIVO DEL PROYECTO

El planteamiento inicial del proyecto se basa en la premisa de la congestión de los hospitales Españoles en urgencias. Este proyecto pretende servir de apoyo a los diferentes hospitales para conocer una cifra aproximada de personas que van a acudir a urgencias. Para ello se creará un modelo entrenado con series temporales que sea capaz de predecir este número mediante la introducción de la meteorología del día siguiente.

DATASET PRINCIPAL

1.- Contexto del dataset

El dataset principal contiene las visitas a urgencias para los años 2024 y 2025 de algunos hospitales de España

2.- Fuente

Se ha obtenido de la siguiente web de forma directa:

<https://datosabiertos.jcyl.es/web/jcyl/risp/es/salud/urgencias-hospitalarias-atendidas/1285114487305.csv>

3.- ¿Qué campos tiene?

El dataset consta de campos básicos como fecha registrada de la visita a urgencias, género y edad del paciente, triaje (nivel de urgencia siendo el 1 el más grave), Ámbito de procedencia (si es rural, urbano, ...) y provincia del hospital al que acudió.

4.- Tratamiento del dataset

Se han cambiado los nombres de las columnas para hacer el trabajo más ameno además de limpiar formatos extraños derivados de las tildes de algunas palabras. Se han eliminado además campos innecesarios para el futuro modelo como fecha de atención (este campo lo generamos nosotros con más información), área y zona básica de salud. Se ha optado por borrar estos campos ya que comprobamos que el área coincidía con la provincia en cada registro y además la zona básica de salud complicaba bastante la lógica de nuestro dataset.

En cuanto a datos nulos, se ha optado por eliminar los registros con cualquier campo vacío ya que consideramos información muy sensible a rellenar con medias o con valores similares al día anterior. Los campos que además nos han aparecido en tipo float como el año por ejemplo, se han pasado a enteros.

Se han generado columnas nuevas importantes tales como pacientes que visitaron urgencias el día anterior y la columna target (pacientes que recibirá el hospital ese día). Se han ordenado las columnas para dejar la columna target al final y como paso importante, se ha ordenado la serie temporal por fecha dada la importancia de mantener el orden temporal de los registros para una futura predicción.

DATASET ADICIONAL

1.- Contexto del dataset

Para complementar el dataset de las urgencias se ha obtenido mediante web scraping la meteorología de las diferentes provincias de los hospitales que aparecen en el dataset principal

2.- Fuente

Para obtener la información de Segovia se ha usado el siguiente enlace:

<https://www.tutiempo.net/estaciones/segovia/{-}/{-}/>

Para obtener el resto de provincias:

<https://www.tutiempo.net/clima/{-}/ws-{}.html>

3.- ¿Qué campos tiene?

El dataset tiene campos básicos de meteorología de los cuales solo vamos a usar día, mes, año, provincia, temperaturas media, máxima y mínima, velocidad del viento media, máxima y mínima, probabilidad o cantidad de precipitación y humedad relativa

4.- Proceso para obtener la info

Para extraer la información de la web se han usado los ID's de las provincias proporcionadas por la propia web (Ávila: 80110 por ejemplo) y el año del que se quiere obtener información, en este caso 2024 y 2025

5.- Tratamiento del dataset

Al haber obtenido dos datasets por separado (Segovia y el resto de provincias) hemos tenido que eliminar las columnas que no eran coincidentes ('SN','TS','RA','VV','FG','VG','SLP'), aunque podían contener información bastante útil como no eran columnas comunes y no podíamos rellenar con medias se optó por eliminar todo lo que no era coincidente. Eliminamos además líneas que traía por defecto el web scraping con medias totales y mensuales. Finalmente concatenamos ambos datasets y como todas las columnas son coincidentes nos queda una información bastante limpia.

CÓMO QUEDA EL DATASET FINAL

Como dataset final nos queda una concatenación de los registros de urgencias para cada día registrado y además columnas nuevas que indican la climatología para esa fecha. Tenemos un total de 22 columnas que han quedado limpias, sin nulos y con valores claros que más adelante se tendrán que transformar para su uso en el modelo. Finalmente decidimos quitar la hora para mayor sencillez a la hora de predecir la cantidad total de pacientes, en una futura versión se planteará añadir la hora. Por el momento los registros resultantes serán una combinación de fecha, provincia y hospital, el resto quedará agrupado bajo esta condición. Los campos finales que tendrá en cuenta el modelo serán:

fecha, hospital, provincia, día de la semana, mes, año, columna target, pacientes de ayer, T.media, T.máxima, T.mínima, viento, viento máximo, precipitaciones y humedad

1.- Agrupaciones para análisis de datos

Para poder obtener gráficas más visibles y amigables se ha optado por agrupar algunos conjuntos de datos que por separado saturan mucho las gráficas. En las siguientes tablas podemos ver qué campo se ha agrupado y qué valor se ha dado con ayuda de una pequeña búsqueda en internet.

1.1.- hora redondeada

Este caso en concreto no dispondrá de tabla ya que únicamente se extrajo la hora a un campo por separado con la condición de si supera los 30 minutos se sumaba +1 a la hora.

1.2.- El resto de grupos

Grupo de edades	
Infante	De 0 a 12 años
Adolescente	De 13 a 17 años
Joven	De 18 a 28 años
Adulto	De 29 a 50 años
Anciano Joven	De 51 a 65 años
Anciano	Mayores de 65 años


Grupos de Temperatura media	
Mucho frío	Menor a 5 grados
Frío	De 6 a 15 grados
Cálido	De 16 a 20 grados
Calor	De 21 a 25 grados
Mucho calor	Mayor a 26 grados

Grupo de precipitaciones	
Sin lluvia	0mm o menor
Llovizna	De 1mm a 2mm
Lluvia moderada	De 3mm a 15mm
Lluvia fuerte	De 15mm a 30mm
Lluvia muy fuerte	De 30mm a 60mm
Lluvia torrencial	Mayor de 60 mm

ANÁLISIS DE LOS DATOS

1.- Heatmap


Lo primero que se ha visualizado ha sido un heatmap para comprobar la relación de las variables entre sí, todas las variables categóricas han sido pasadas a numéricas para poder visualizar este heatmap:



Según se muestra la variable `target_pacientes` sólo tiene relación estrecha con las variables `fecha`, `hospital`, `año` y los `pacientes` recibidos el día anterior. Como era de esperar además, las variables climatológicas sí que tienen relación entre ellas, `temperatura media` con `temperatura máxima` y `mínima`; y el `viento` con la `velocidad máxima del viento`. Vemos también que hay una pequeña relación entre el `mes` y las `temperaturas`, seguramente aquí entran en juego las estaciones del año.


2.- Pacientes por mes y año

Para esta gráfica es importante recalcar que se han eliminado los meses de `septiembre`, `octubre`, `noviembre` y `diciembre` de `2025` ya que este año no se encontraron datos en el dataset original ni en la web. Además, visto el notable aumento de visitas desde `diciembre del 2024` hasta `enero del 2025` dimos por hecho que el dataset podría estar sesgado ya que tras eliminar los duplicados en ambos años, estos registros no sumaban apenas 200. Aún así consideramos que no es un problema trabajar con más datos de un año que de otro.




3.- Ámbito por paciente

Registros por ámbito de procedencia




Como era de esperar, el ámbito urbano tiene un mayor porcentaje de visitas al hospital ya que tiene mayor porcentaje de población en ciudades y pueblos grandes. Al tener mayor congestión de personas hay por lo tanto mayor probabilidad de tener un accidente.

4.- Predominancia de edades por visitas



En este caso podemos ver que las personas que más acuden a urgencias son los mayores de 65 años. Esto tiene bastante sentido teniendo en cuenta que son los más propensos a sufrir lesiones graves con pequeñas caídas o malas posturas además de tener una salud más delicada debido a su avanzada edad.


5.- Predominancia del género y el triaje



Se ha tenido que añadir el nivel de triaje 0 para todos aquellos registros que contenían un “desconocido” en el campo del triaje, así que para este análisis este nivel queda fuera. Lo primero que se puede apreciar es que las mujeres van más a urgencias que los hombres y además, su nivel de triaje mayor, al igual que el de los hombres, es un 4, esto significa que no fueron por algún motivo que se considera urgente en el ámbito hospitalario.


Cabe destacar que también predominan las mujeres en caso de triaje 3, considerado ya una urgencia real.

6.- Predominancia de edad y triaje




Dentro del grupo de edad ya hemos visto que los que predominan visitando urgencias son los mayores de 65 años, ahora podemos además que su causa principal de visitas a urgencias está considerado como urgente a diferencia del resto de edades que su visita se considera mayoritariamente no urgente.

7.- Horas puntas en urgencias




En esta gráfica podemos ver cómo tenemos unas “horas valle” de 2 de la mañana a 11 de la mañana y que las horas más congestionadas suelen ser de entre las 17:00 a 21:00 de la noche.

8.- Temperatura media con más visitas a urgencias



Lo primero que podemos pensar si relacionamos las urgencias con la temperatura es en posibles golpes de calor o temperaturas bajas propias de una mayor cantidad de gripes y en esta gráfica redonda podemos ver que quizás no está tan relacionado con posibles golpes de calor si no más con posibles gripes ya que sabemos que la causa principal de visitas a urgencias no están catalogadas como urgentes.

9.- Precipitaciones por visitas a urgencias



Por último se pretende comprobar si la lluvia afecta más a las visitas a urgencias ya que es más propicia a crear accidentes en carreteras, caídas por suelos resbaladizos, etc. Por el contrario podemos ver que cuando más visitas se han registrado ha sido cuando no había lluvias en ese momento. Esto no significa que no exista una cierta influencia a la hora de acudir al hospital ya que en nuestro territorio no existen lluvias constantes, por lo tanto no podemos descartar que sea un factor importante.

CONCLUSIONES TRAS VISUALIZAR LAS GRÁFICAS

Con todas las gráficas y análisis realizados se puede concluir que la demanda en urgencias sigue patrones temporales y demográficos bastante claros, lo que permitiría optimizar la preparación de recursos humanos y materiales dentro del hospital. Los

resultados muestran que las horas de mayor congestión se concentran principalmente entre las 17:00 y las 21:00, mientras que las horas de menor actividad se sitúan entre las 02:00 y las 11:00. Esto sugiere que una planificación dinámica de personal sanitario podría ayudar a reducir tiempos de espera y mejorar la atención en los momentos de mayor presión asistencial.

Además, el grupo de población que más acude a urgencias corresponde a personas mayores de 65 años, siendo también el grupo con mayor proporción de casos considerados realmente urgentes. Esto implica que los servicios de urgencias deberían priorizar recursos orientados a pacientes geriátricos, como mayor disponibilidad de camas, material de movilidad, personal especializado y protocolos adaptados a patologías frecuentes en personas mayores.

También se observa que gran parte de las visitas corresponden a niveles de triaje no urgentes, especialmente en triaje 4, lo que puede indicar un uso de urgencias para patologías leves o problemas que podrían tratarse en atención primaria. Esta información resulta útil para planificar circuitos rápidos de atención, reforzar consultas ambulatorias o redistribuir recursos en determinadas franjas horarias.

Respecto a los factores meteorológicos, aunque no se encontró una relación directa fuerte entre altas precipitaciones y un aumento significativo de visitas, sí se aprecia una posible influencia de temperaturas bajas en el incremento de asistencias, probablemente relacionadas con enfermedades respiratorias o infecciosas. Esto permitiría anticipar épocas con mayor presión asistencial y preparar con antelación recursos médicos, personal y material sanitario específico.

En conjunto, el análisis demuestra que la predicción temporal de visitas a urgencias puede convertirse en una herramienta muy útil para mejorar la gestión hospitalaria, permitiendo anticipar momentos de saturación y optimizar tanto la distribución del personal como la disponibilidad de recursos materiales y asistenciales.

LLAMADA A LA API PARA OBTENER CLIMATOLOGÍA

La web utilizada para hacer la llamada a la API que nos proporcionará la información necesaria para enviar el modelo ha sido: <https://open-meteo.com>

Para obtener la información hemos creado un mapeo aproximado de latitud y longitud de las provincias utilizadas ya que otras APIs que nos permitía usar el ID de la provincia para algo más concreto nos daba información más pobre. Lo único que hemos tenido que hacer tras realizar la llamada ha sido transformar el nombre de las columnas para que fueran iguales a las nuestras y transformar esa información en un dataframe.

TRANSFORMACIÓN DE DATOS


Tras obtener el dataset final que usaremos para el modelo, lo único que hemos tenido que hacer ha sido transformar las variables categóricas a numéricas y la fecha a datetime.

USANDO MODELOS PREDEFINIDOS


1.- PROPHET

Sabiendo que es la más rápida y flexible de implementar lo hemos puesto el primero, sabiendo además que probablemente era el que peor resultado nos iba a dar. Este modelo se ha probado con dos provincias, hemos escogido Salamanca y Segovia porque al tener solo un hospital sabemos con certeza que al haber eliminado las horas no habrá registros duplicados de fecha.

Este ha sido el resultado para la predicción de prophet en la provincia de Salamanca. Además el error obtenido medio ha sido de 9.30 pacientes por día



El resultado de Segovia ha sido el siguiente, donde el error medio obtenido ha sido de 11.73 pacientes por día:



Aunque no ha sido un modelo super preciso el resultado ha sido bastante satisfactorio ya que en ambos casos el error medio ha estado por debajo de 12 pacientes diarios.


1.1.- Transformaciones para prophet

Este modelo en concreto nos pedía tener dos columnas con los nombres; ds para la fecha; y para la columna target.

2.- SARIMAX


Este modelo teóricamente es el que mejor se ajusta a nuestras necesidades, por eso lo implementamos el último, para ver obtenemos mejores resultados. Se probará con las mismas provincias que prophet para mejor comparativa de resultados, además de que tampoco acepta registros de fechas duplicadas, por lo tanto no nos ha quedado otra que usar dos provincias que solo tenían un hospital.

El resultado obtenido para este modelo en Salamanca ha sido:



A pesar de que el error medio ha sido muy parecido a prophet creemos que con más datos de entrenamiento acabará con una mejor predicción pues los intervalos de confianza a nuestro parecer son bastante más exactos que prophet, se aprecia que no hay tantos puntos verdes fuera del intervalo.

El resultado para Segovia:



En este caso pasa lo mismo que en Salamanca, el error medio ha sido de 12.88 pero los intervalos de confianza han sido mucho más acertados que en prophet

1.1.- Transformaciones para Sarimax


Este modelo en concreto nos pedía tener dos columnas con los nombres; ds para la fecha; y para la columna target. Además, nos hemos asegurado de que las fechas estuvieran ordenadas pues es de vital importancia para este modelo.

3.- ARIMA Y ALISADO EXPONENCIAL


Estos modelos han sido descartados ya que no manejan datos climatológicos y por lo tanto se nos quedan cortos. Además, teniendo en cuenta que Sarimax es la evolución de Arima decidimos implementar directamente Sarimax.

COMPARANDO MODELOS PREDEFINIDOS

La primera gráfica compara el modelo prophet y sarimax para la provincia de Salamanca:



Tal y como ya sabemos, el error medio ha sido ligeramente peor en sarimax, sin embargo, aquí no queda representado el intervalo de confianza. En una futura versión o mejora se pasarán las fechas incluyendo la hora y con esto lograremos tener muchos más datos para pasarle al modelo. En la comparativa de Segovia podemos ver exactamente lo mismo:



EJEMPLO REAL

Como caso práctico real hemos creado una función que devuelve un número aleatorio de entre el máximo y el mínimo de pacientes registrados para las dos provincias que trabajaremos (Salamanca y Segovia), los valores han sido 37 como mínimo y 152 como máximo. Las variables de día y mes van variando según el día y mes de ejecución, si lo ejecutamos el día 1 de enero del 2025, el día que enviaremos al modelo será 2 de enero del 2025 y lo mismo con el día de la semana, si cae un lunes pondremos un 0 tal y como está en el mapeo manual. Por último llamamos a la API para obtener los datos climatológicos del día siguiente y ya solo nos queda montar el dataset de un registro que mandaremos al modelo y obtener la predicción. HACERLO CON SARIMAX TAMBIÉN.

CÓMO EJECUTAR EL CÓDIGO

El código se ha desarrollado en google colab por lo que recomendamos ejecutarlo en ese entorno. Todos los ficheros se ejecutan de forma secuencial, lo único que hace falta es algún csv para trabajar sobre esos datos. Se detalla más abajo.


El orden de ejecución es la siguiente, para el primer fichero, web scraping no hay que cargar ningún documento, pues este fichero nos proporcionará el primer dataset para trabajar, esta información contiene los datos climáticos. El segundo fichero a ejecutar será el fichero de limpieza, para ejecutarlo debemos proporcionarle el fichero obtenido en la ejecución de web scraping y además el dataset nuevo que contiene la información de los hospitales. Este será nuestro dataset principal. El siguiente fichero será el de análisis y solo debemos proporcionarle el fichero resultado de la ejecución de la limpieza. El análisis además de proporcionarnos información interesante de los datos también nos dará el dataset final con el que entrenaremos al modelo, a falta de transformar los datos.

MEJORAS OPCIONALES PARA FUTURAS VERSIONES

Hasta aquí consideramos que es suficiente para demostrar el valor mínimo de nuestra propuesta de proyecto, lo que se expone a continuación son mejoras que hemos podido implementar que consideramos que mejora bastante la calidad de nuestro desarrollo.

PRIMERA MEJORA

Se ha agregado la hora a cada registro de visita a urgencias y como resultado hemos obtenido casi medio millón de registros. Esto ha ocasionado que tuviéramos que cambiar de modelo de Sarimax a Lightgbm, ya que este es más eficiente entrenando con una gran cantidad de datos. Como resultado hemos obtenido una tasa de acierto bastante mayor como se ve en la gráfica:



SEGUNDA MEJORA

Como última mejora se ha creado una pequeña interfaz gráfica para facilitar la visualización de resultados e introducción de datos al usuario final:

Predicción de Pacientes en Urgencias

Introduce los parámetros y obtén la predicción.

Provincia

León

Hospital

C.A.U. León

Pacientes ayer

232

Pacientes a las 22:00

129

Pacientes hace 24h

178

Media pacientes hace 24h

208

Realizar predicción

Resultado

Pacientes previstos: 157.21